

Scrapping des données

Elaboré par:

- Rekik Wiem
- Dhaouadi Mohamed Amine
- Dghaies Yasser
- Ferjani Mohamed Iheb
- Battikh Anis
- Achour Nouha

I. Introduction

Ce script Python utilise les bibliothèques Selenium et BeautifulSoup pour extraire des données à partir d'une page Web contenant un tableau de données. L'objectif principal est de récupérer les informations de la page sur les collisions de véhicules à New York depuis le portail de données ouvert de la ville.

II. Données Source

Le tableau de données présente les accidents liés aux collisions de véhicules automobiles à New York, fournissant des détails sur chaque incident spécifique. Chaque ligne de ce tableau représente un événement de collision distinct, présentant des informations telles que la date, l'heure, l'emplacement, les véhicules impliqués, et d'autres détails pertinents. Ces données sont compilées à partir des rapports officiels de la police, offrant une vue d'ensemble complète et détaillée des collisions de véhicules à moteur dans la région

III. Outils











IV. Script

```
: from selenium import webdriver
  from selenium.webdriver.common.by import By
  from selenium.webdriver.chrome.options import Options
  from selenium.webdriver.support.ui import WebDriverWait
  from selenium.webdriver.support import expected_conditions as EC
  from selenium.common.exceptions import StaleElementReferenceException
  from bs4 import BeautifulSoup
  import pandas as pd
  import time
  def initialize_driver():
      options = Options()
      options.add_argument('--headless')
      return webdriver.Chrome(options=options)
  def wait_for_element(driver, locator, timeout=10):
      return WebDriverWait(driver, timeout).until(EC.presence_of_element_located(locator))
  def click_and_retry(driver, element, locator, retry_attempts=3):
      for _ in range(retry_attempts):
          try:
              element.click()
              return True
          except StaleElementReferenceException:
              print("Stale Element Reference Exception. Retrying...")
              element = wait_for_element(driver, locator)
          except Exception as e:
              print(f"An error occurred: {str(e)}")
              return False
      return False
  def scrape_table_data(driver, table_locator):
      table = wait_for_element(driver, table_locator)
      table_html = table.get_attribute('outerHTML')
      soup = BeautifulSoup(table html, 'html.parser')
      html_table = soup.find('table')
      return pd.read_html(str(html_table))[0]
```

```
def main():
    url = "https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Crashes/h9gi-nx95"
    driver = initialize_driver()
    try:
        driver.get(url)
        driver.implicitly_wait(10)
        table locator = (By.CLASS NAME, 'socrata-table.frozen-columns')
        if not (table := wait_for_element(driver, table_locator)):
            print("No table found on the page with class 'socrata-table frozen-columns'.")
            return
        dfs = []
        total_pages = 500
        for page in range(1, total_pages + 1):
            next_button_locator = (By.XPATH, "//button[@class='pager-button-next']")
            next_button = wait_for_element(driver, next_button_locator)
            if not click_and_retry(driver, next_button, next_button_locator):
                print("Failed to click next button. Exiting.")
                break
            time.sleep(3)
            df = scrape_table_data(driver, table_locator)
            print(df.head())
            dfs.append(df)
        result_df = pd.concat(dfs, ignore_index=True)
        result_df = result_df.dropna(axis=1, how='all')
                                                                             ChatGPT - Google Chrome
```

```
result_df = result_df.dropna(axis=1, how='all')

result_df.to_excel("DataCollisions.xlsx", index=False)
print("Cleaned data successfully exported DataCollisions.xlsx")

except Exception as e:
    print(f"An error occurred: {str(e)}")

finally:
    driver.quit()

if __name__ == "__main__":
    main()

Nan HARLEM RIVER DRIVE RAMP
```

Étape 1 : Initialisation du WebDriver

Le script débute en initialisant un WebDriver Chrome en mode headless à l'aide de la bibliothèque Selenium. Cette étape permet une navigation automatisée sur la page Web sans interface graphique.

Étape 2 : Navigation vers la Page Cible

Le WebDriver accède à la page de données des collisions de véhicules à New York en utilisant l'URL spécifié. Une attente implicite garantit que la page est entièrement chargée avant de procéder à la collecte des données.

Étape 3 : Scraping de Données

Le script identifie le tableau de données sur la page (repéré par la classe CSS 'socrata-table.frozen-columns') et commence le processus d'extraction des informations. La pagination automatique est gérée pour collecter les données de plusieurs pages.

Étape 4 : Gestion des Éléments Dynamiques

Les mécanismes de gestion des éléments dynamiques, tels que l'utilisation de l'attente explicite et la gestion des exceptions Stale Element Reference, sont mis en œuvre pour assurer la fiabilité du scraping, même sur des pages dynamiques.

Étape 5 : Nettoyage des Données

Une fois les données collectées, le script les nettoie en supprimant les colonnes qui ne contiennent que des valeurs nulles, optimisant ainsi la qualité et la lisibilité du jeu de données.

Étape 6 : Exportation des Données Nettoyées

Les données nettoyées sont ensuite exportées vers un fichier Excel, facilitant leur utilisation dans des analyses ultérieures ou d'autres applications.

_/ A	В	C	D	E	F	G	Н	- 1	J	K	L	M	N	0	Р		Q	R	S	T	U	V	W	
39 04/11/202	5:28	BROOKLYN	11230	40.63529	-73.9582	(40.63529)	OCEAN AV	FARRAG	JT ROAD	0	0	0	0	0		0	0		0 Fell Aslee	Duspecified	1			4
04/11/202	5:30	QUEENS	11417	40.67917	-73.8532	(40.67917°	, -73.85315	r°)	105-29 84	0	0	0	0	0		0	0		0 Driver Ina	t Unspecifie	Unspecified			4
1 04/11/202	6:05			40.61131	-74.0984	(40.61131	CLOVE RO.	NARROV	VS ROAD NOI	2	0	0	0	0		0	2		0 Reaction	t Unspecified	i			4
2 04/11/202	6:06			40.86794	-73.8722	(40.86794)	BRONX RIV	ER PARK	WAY	3	0	0	0	0		0	3		0 Unsafe La	Unspecified	i			4
3 04/11/202		MANHATT		40.78423	-73.9788	(40.784225	°, -73.9787	'9°)	222 WEST	0	0	0	0	0		0	0		0 Driver Ina					4
14 04/11/202	6:40	QUEENS	11691				ROCKAWA	BEACH 3	8 STREET	0	0	0	0	0		0	0		0 Other Vel			rded		4
15 04/11/202		BROOKLYN				(40.63781°			1414 EAST	0	0	0	0	0		0	0		0 Driver Ina					4
6 04/11/202	7:14	BROOKLYN	11212	40.66353	-73.9131	(40.66353	DUMONT.	AMBOY	STREET	1	0	0	0	0		0	1		0 Unspecifi	e Unspecifie	Unspecified			
17 04/11/202	7:15	QUEENS	11356	40.78322	-73.8459	(40.78322)	18 AVENU	COLLEGI	POINT BOU	1	0	0	0	0		0	1		0 Following	Unspecified	i			
18 04/11/202	7:20	BROOKLYN	11226	40.65134	-73.9566	(40.65134°	, -73.95657	r*)	75 MARTE	0	0	0	0	0		0	0		0 Unspecifi	e Unspecified	i			
19 04/11/202	7:40	QUEENS	11379	40.70826	-73.8751	(40.70826°	,-73.87514	°)	69-23 76 S	0	0	0	0	0		0	0		0 Fell Aslee	Du Unspecifie	Unspecified			
04/11/202	7:50	BROOKLYN	11234	40.62303	-73.9254	(40.623028	3°, -73.9253	(8°)	1490A EAS	0	0	0	0	0		0	0		0 Passing o	Unspecified	1			
1 04/11/202	7:59			40.74984	-73.939	(40.74984	QUEENS P	28 STREI	T	1	0	0	0	0		0	1		0 Following	Unspecified	1			
2 04/11/202	8:30			40.74901	-73.8347	(40.74901	VAN WYCK	EXPWY		0	0	0	0	0		0	0		0 Driver Ine	xperience				
3 04/11/202	8:30	BROOKLYN	11237	40.69426	-73.9104	(40.69426)	JEFFERSON	KNICKER	BOCKER AVE	1	0	0	0	0		0	1		0 Fell Aslee	Unspecified	i			
4 04/11/202	8:35	QUEENS	11375	40.73095	-73.8486	(40.73094)	65 ROAD	108 STRI	ET	0	0	0	0	0		0	0		O Passing o	Unspecifie	Unspecifie	Jnspecifie I	Jnspecifi ^c	ie
5 04/11/202	8:50			40.63667	-74.0257	(40.63667	3 AVENUE	68 STREI	T	0	0	0	0	0		0	0		0 Alcohol Ir	Unspecified	1			
6 04/11/202	9:00	BROOKLYN	11234	40.61826	-73.9347	(40.618256	5°, -73.9346	i6°)	1608 COLE	0	0	0	0	0		0	0		0 Unspecifi	ed				
7 04/11/202	9:00	QUEENS	11372	40.75048	-73.8775	(40.750477	r°, -73.8774	6°)	89-27 37 A	0	0	0	0	0		0	0		0 Unspecifi	e Unspecified	1			
8 04/11/202	9:00	QUEENS	11373	40.74058	-73.8903	(40.740578	3°, -73.8902	!74°)	45-12 74 S	0	0	0	0	0		0	0		0 Driver Ina	t Unspecified				
9 04/11/202	9:15			40.70003	-73.7887	(40.70003	MERRICK I	107 AVE	NUE	0	0	0	0	0		0	0		0 Unsafe La	Unspecified				
0 04/11/202	9:29	BRONX	10472	40.82737	-73.8574	(40.827374	°, -73.8573	5°)	1973 CHAT	0	0	0	0	0		0	0		0 Driver Ina	t Unspecified				
1 04/11/202	9:30			40.7221	-73.7777	(40.72209	GRAND CE	NTRAL P	KWY	1	0	0	0	0		0	1		0 Driver Ina	ttention/Dis	traction			
2 04/10/202	0:00	MANHATT	10018	40.75517	-73.9913	(40.75517°	,-73.99129	l°)	594 8 AVEI	0	0	0	0	0		0	0		0 Driver Ina	t Unspecifie	Unspecified			
3 04/10/202	0:00	MANHATT	10033	40.84706	-73.9382	(40.84706°	,-73.93818	l°)	4162 BRO/	0	0	0	0	0		0	0		0 Driver Ina	ttention/Dis	traction			
4 04/10/202	0:00	QUEENS	11414	40.66317	-73.8409	(40.663166	°, -73.8408	6°)	156-71 CR	0	0	0	0	0		0	0		0 Unspecifi	ed				
5 04/10/202	0:00			40.70644	-73.7597	(40.70644)	HOLLIS AV	198 STRI	ET	0	0	0	0	0		0	0		0 Driver Ina	t Unspecified				
6 04/10/202	0:00						VICTORY B	OULEVA	RD	0	0	0	0	0		0	0		0 Unspecifi	e Unspecified				
7 04/10/202	0:00			40.81603	-73.9395	(40.81602	WEST 138	STREET		0	0	0	0	0		0	0		0 Driver Ina	t Unspecified				

4 B B	. Aug	D	T.	F 16		U.	. America		14	A	88		N	0		0	18	N. W.	. 1	ii.
6476 03/30/302 14:00	BROOKLY#	11226	40.65279	-73.9469 140.65					1	11		D:	- 6	1	13	. 0		d Unspecific	et .	
6477-03/20/200 14:00	BEOORLYS	11236	40.64141	73,9123 (40.64)	40: FARM	AGUITE	EAST NO STR	EET	1	n		D:	. 0		0	- 1		0 Umpecific	Umperited	
6478 /09/20/202 14:05	BROKK	10467			EAST	FORCE	PELHAM PAR	WWW	1	0		D:		1	0	0		0. Feilure to	Unspecified	
1470 03/20/20214:08	QUEENS	11435	40.65759	73.8335 (40.69)	257 94.88	MNILI	DIFFACE		1	- 0		D.		0	00.5	-1		O Parning or	Uniperified	
H88 09/20/20214:30	QUEENS	11434	40.68257	73.7527 140.66	2561116 A	WENDS	SUTPHIN BO	SHOVELUN	0	. 0		0	. 0	. 0	0	. 0		0 Umpedile	Unipecified	
6481 03/20/202 14:30			40.75042	73.9518 [40.79	HI MACK	SON W	WENUE		0	0		D		0	0	. 0		O Lout Come	Umpecifie U	пресбе
BHE2 03/30/302.14:34	QUEENS	11354	40,75586	73.8362;140.750	495°, -T3.1	836157	1	31-66-85	0	0		0		0	0	.0		0. Turning in	Umpecified	
5483 05/20/202 14:36	QUEENS	11,971	40,7418	73.8788 [46.74]	8', 73.8	78811		6-12 WHI	1	0		0	. 0	0	0	1		O Turning by	timper fied	
MISS 03/20/202 14:38:	MUNHATT	10028	0	0.40.01,0	W.		1	536 3.WI	0	- 0		0	. 0	. 0	0.0	.0		0. Backing U	Unipecified	
HRS 00/20/20214:45			40.68316	73,5381 (40.66)	SIN' HALS	EY ST81	EET		1	0		1		0	0	. 0		O Driver Inc.	continu'Distri	action
6400 GU/20/20214:48	BROOKLYR	31228	0	0.90,05,0	07)		2	069 EAST	0	.0		D	. 0	0	0.	- 0		O Backing U	Unspecified	
MUT 05/20/202 14:48	MANHATT	10017	40,75374	73,9678 (40.75)	741, 73	196783	17	48 EAST 4	0	0		0	. 0	. 0	0	. 0		O Driver Hu	Umperified	
MIN 03/30/303 14:49	HRONX	10467	0	0 (0.0", 0	O') \$808	K FA V	WARING AV	ENVIE	0	. 11		n		0	ti .	. 0		O Debes tres	Unspecified	
HIRI 03/20/207 \$4:30	BRONK	10472	40.82975	-73.8757 (40.82)	775-HARR	OO AY	WESTCHEST	ER AVENI	0.	. 0		0:	. 0	.0	0	. 8		0 Urapecifie	d b	
94:N1 X0X/X0X VA:56	CHIEFNS	11437	. 0	0.10.01,0	0") 1AWA	UEA / L	TALF BOL		0	U		0		. 0	U	. 0		0 Driver trai	Umperified	
1491 03/20/202 15:00	BROAK	10460	40.83824	71.8767 140.83	231 EAST	17738	вистик ежен	EAVENUE	0.	.0		0		0	0			O Driver Inc.	Driver leatter	ntinn/Ois
1492 01/30/202 15:00	BROOKLYK	11221	. 0	0 (0.0*,0	107			SILMONE	0	.0		0.		. 0	0.			0 Driver inst	Unspecified	
HILL 03/20/202 12:00			40,86042	-73.8443 140.88	147 EAST	11350	REET		0	. 0		D.			0	. 0		O Uvsafe Sp	Unspecified.	
6404 00/30/202 55:04			40,70245	73,8594 (40.70)	MS-IACKI	is hope	INSON PROV	ry:	0	- 0		D:	. 0	.0	0	: 0		O Beaction t	a Unimedied	Vahide
6495 -08/20/202 15:05	BRONX	1046E	40.88721	73.8608 140.88	2075 - 73	86082	n i	949 WHD	2	.0		2		.0	0.	.0		0 Driver Inc.	perience	
HUIL-00/20/202-15:12			40,67269	73,7354 (40.67)	NOR LADE	ILLTON	S. PARKWAY		0	0.00		D.		0	0.0	. 0		0 Umpecifie	Unipecified	
H497-09/20/20115:25	BRONK	10455	40.60988	-73.9091 140.80	188 EAST	14958	BRUCKNER	BOULEVA	1.	. 0		0	- 0.	0	0	- 1		() Unspecifie	Unspecified	
1404 00/20/202 15:25	QUEENS	11354	40.76582	73.8337 (46.78)	87, 35 AV	AND P	PARSONS DO	DIVENNO	100	. 0		1		0	0.	0		O Fathern to	York Right of	Way
6499 03/20/202 15:30	QUEERS	11377	40,7687	-78.874 (40.74)	77,-73-8	7395")	. 9	Q-17 RCC	1	- 30		0	- 8	1	000	- 0		() Umpecific	d	
EDDEC 00/20/200 15:31	BECOMES	11217	. 0	0 (0.0*, 0	(0")		1	IIII FLATIL	0	- 0		0	. 0	0	0	0		O Passenger	View Obstruc	rad/Limit
6501 09/20/20115:40			0	0.10.0*, 0	OT) CHRY	STIE ST	THEET		18	.0		D	10.	0	000	1		0 Physical D	(Unspecified	